

FGV EMAp

Ciência de Dados e Inteligência Artificial

Aprendizado de Máquina Aplicado à Alocação de Portfólios no Mercado Acionário Brasileiro

Maria Eduarda Mesquita Magalhães

Trabalho de Conclusão de Curso apresentado à FGV EMAp como requisito parcial para obtenção do grau de bacharel em Ciência de Dados e Inteligência Artificial.

Orientador(a): Yuri Saporito

Rio de Janeiro

2026

Resumo

Este trabalho investiga se modelos de aprendizado de máquina podem melhorar a construção de portfólios quando combinados com a otimização média-variância de Markowitz. Uma das principais dificuldades práticas dessa abordagem é estimar os retornos esperados: pequenas variações nessas estimativas podem produzir grandes alterações nos pesos ótimos. Para estudar esse problema, desenvolve-se um procedimento quantitativo que utiliza modelos supervisionados para prever os retornos de ações brasileiras e, em seguida, aplica a otimização de Markowitz, com estimação regularizada da matriz de covariância, para determinar os pesos da carteira.

O universo configurado contém vinte empresas brasileiras de grande porte e liquidez, das quais dezenove integram a base efetiva da execução analisada. São avaliados modelos lineares regularizados, como Lasso, Ridge e Elastic Net; modelos não lineares, como Random Forest, Gradient Boosting e XGBoost; e a média histórica como referência preditiva. A matriz de covariância é estimada pelo método de Ledoit-Wolf. As carteiras são avaliadas por meio de um backtest com janela móvel, rebalanceamento aproximadamente mensal, proibição de venda a descoberto e limite máximo de alocação por ativo.

Os resultados são comparados com duas referências: uma carteira igualmente ponderada e o índice Ibovespa. As métricas de avaliação incluem retorno acumulado, índice de Sharpe, drawdown máximo, turnover, erro médio absoluto, erro quadrático médio e acurácia direcional. O trabalho também discute diagnósticos importantes do experimento, como a anualização adequada do Sharpe, o alinhamento entre as janelas de treino e teste, a sensibilidade aos custos de transação e a concentração dos pesos.

Palavras-chave: otimização de portfólios; Markowitz; aprendizado de máquina; Lasso; XGBoost; backtest; mercado brasileiro.

Sumário

Resumo **1**

1 Introdução **4**

1.1 Motivação 4

1.2 Objetivos 4

2 Fundamentação Teórica **5**

2.1 Estimação da Matriz de Covariância por Encolhimento Linear 5

3 Modelos de Aprendizado de Máquina **7**

4 Metodologia **7**

4.1 Universo de Ativos 7

4.2 Período Amostral 8

4.3 Configuração Experimental 8

4.4 Justificativa dos Hiperparâmetros 9

4.5 Algoritmo do Backtest 9

4.6 Benchmarks 12

5 Métricas de Avaliação **12**

6 Resultados **13**

6.1 Tabela de Desempenho 13

6.2 Retorno Acumulado 14

6.3 Drawdown 15

6.4 Risco versus Retorno 16

6.5 Resumo das Métricas 17

6.6 Pesos Médios 18

6.7 Diagnósticos do Backtest 19

7 Discussão dos Resultados **20**

7.1 Desempenho Financeiro e Qualidade Preditiva 20

7.2 Benchmarks e Composição das Carteiras 20
7.3 Sensibilidade e Implicações Práticas 21
7.4 Alcance da Análise e Extensões 21

8 Conclusão **22**

1 Introdução

1.1 Motivação

A construção de portfólios é um dos problemas centrais em finanças quantitativas. Investidores buscam distribuir capital entre diferentes ativos de modo a obter retorno compatível com seu apetite a risco. Desde o trabalho seminal de Markowitz [1], a alocação média-variância tornou-se uma das principais formulações matemáticas para esse problema, pois oferece uma estrutura clara para relacionar retorno esperado, risco e diversificação.

Apesar de sua importância teórica, a aplicação prática da teoria de Markowitz apresenta dificuldades relevantes. A mais conhecida é a sensibilidade da solução aos parâmetros de entrada. Em particular, o vetor de retornos esperados é difícil de estimar e, quando estimado com ruído, pode gerar carteiras instáveis, concentradas ou pouco robustas fora da amostra.

Nos últimos anos, modelos de aprendizado de máquina passaram a ser utilizados em finanças para previsão de retornos, classificação de ativos, modelagem de risco e detecção de padrões em séries temporais. Esses modelos oferecem flexibilidade para explorar relações não lineares e interações entre variáveis, mas também trazem riscos de sobreajuste, especialmente em mercados financeiros, onde o sinal preditivo costuma ser fraco.

Diante disso, este trabalho investiga uma pergunta aplicada:

Modelos de aprendizado de máquina melhoram a estimação de retornos esperados e, quando combinados com Markowitz regularizado, geram carteiras superiores às estratégias tradicionais?

1.2 Objetivos

O objetivo geral deste trabalho é avaliar o desempenho de carteiras construídas a partir de previsões de retornos geradas por modelos de aprendizado de máquina e otimizadas por uma formulação regularizada de Markowitz.

Os objetivos específicos são:

1. construir uma base de retornos de ações brasileiras grandes e consolidadas;
2. implementar modelos preditivos para estimar retornos esperados;

3. estimar a matriz de covariância dos ativos por Ledoit-Wolf;
4. resolver uma otimização de Markowitz com restrições práticas;
5. comparar os resultados com uma carteira igualmente ponderada e com o Ibovespa;
6. avaliar métricas financeiras e preditivas;
7. diagnosticar possíveis fontes de distorção, como anualização incorreta, vazamento temporal, custos de transação e concentração excessiva.

2 Fundamentação Teórica

O retorno diário do ativo i, calculado por $r_{i,t} = P_{i,t}/P_{i,t-1} - 1$, é a base da modelagem e da alocação.

A abordagem de Markowitz relaciona o retorno esperado da carteira, $\mathbf{w}^T\hat{\boldsymbol{\mu}}$, ao seu risco, $\mathbf{w}^T\hat{\Sigma}\mathbf{w}$, em que $\mathbf{w}$ representa os pesos, $\hat{\boldsymbol{\mu}}$ os retornos esperados estimados e $\hat{\Sigma}$ a matriz de covariância estimada. Neste trabalho, os pesos são obtidos pela seguinte otimização média-variância:

$$\max_{\mathbf{w}} \quad \mathbf{w}^T\hat{\boldsymbol{\mu}} - \gamma\mathbf{w}^T\hat{\Sigma}\mathbf{w} \tag{1}$$

sujeita a $\sum_i w_i = 1$ e $0 \leq w_i \leq 0{,}15$. O parâmetro γ controla a penalização do risco. A regularização empregada no estudo ocorre na estimação da matriz de covariância pelo método de Ledoit-Wolf, e não por uma penalização adicional sobre os pesos.

A matriz de covariância é estimada pelo método de Ledoit e Wolf [2], que combina a matriz amostral S com uma matriz-alvo proporcional à identidade:

$$\hat{\Sigma}_{LW} = (1-\delta)S + \delta\mu I, \tag{2}$$

em que $\mu = \mathrm{tr}(S)/p$ e δ é a intensidade de encolhimento estimada pelo método. Essa regularização da matriz de covariância busca reduzir o ruído de estimação. O índice de Sharpe [3], usado na avaliação, é definido no Seção 5.

2.1 Estimação da Matriz de Covariância por Encolhimento Linear

Quando a dimensão p é comparável ao número de observações n, a matriz de covariância amostral $S = XX^t/n$ pode ficar mal condicionada ou até singular (se $p > n$),

o que compromete sua inversão. Para reduzir esse problema, adotou-se o estimador de Ledoit e Wolf [2], que combina S com a matriz identidade escalada por μ:

$$S^* = \frac{b^2}{d^2}\, mI + \frac{a^2}{d^2}\, S, \tag{3}$$

em que o termo mI é o alvo de encolhimento e b^2/d^2 é a intensidade de encolhimento.

Critério de otimalidade

Utiliza-se a norma de Frobenius normalizada pela dimensão, $\|A\|^2 = \operatorname{tr}(AA^t)/p$, de modo que $\|I\| = 1$. Definem-se os escalares populacionais

$$\mu = \Sigma \circ I, \quad \alpha^2 = \|\Sigma - \mu I\|^2, \quad \beta^2 = E\left[\|S - \Sigma\|^2\right], \quad \delta^2 = E\left[\|S - \mu I\|^2\right], \tag{4}$$

que satisfazem $\alpha^2 + \beta^2 = \delta^2$. A combinação $\Sigma^* = \rho_1 I + \rho_2 S$ que minimiza a perda quadrática esperada é

$$\Sigma^* = \frac{\beta^2}{\delta^2}\, \mu I + \frac{\alpha^2}{\delta^2}\, S, \qquad E\left[\|\Sigma^* - \Sigma\|^2\right] = \frac{\alpha^2 \beta^2}{\delta^2}. \tag{5}$$

O ganho relativo sobre S (PRIAL) é igual a β^2/δ^2, isto é, à própria intensidade de encolhimento.

Estimador implementável

Como Σ^* depende de quantidades não observáveis, os escalares são substituídos por estimadores consistentes sob a assintótica geral ($p, n \to \infty$ com p/n limitado):

$$m = S \circ I = \frac{1}{p} \operatorname{tr}(S), \tag{6}$$

$$d^2 = \|S - mI\|^2, \tag{7}$$

$$\bar{b}^2 = \frac{1}{n^2} \sum_{k=1}^{n} \left\| x_{\cdot k} x_{\cdot k}^t - S \right\|^2, \qquad b^2 = \min\left(\bar{b}^2, d^2\right), \tag{8}$$

$$a^2 = d^2 - b^2, \tag{9}$$

em que $x_{\cdot k}$ é a k-ésima observação. A restrição $b^2 \leq d^2$ garante $a^2 \geq 0$ e, portanto, que S^* seja uma combinação convexa.

Propriedades

- **Otimalidade assintótica:** S^* tem risco quadrático assintoticamente mínimo na classe das combinações lineares de I e S, inclusive aquelas com coeficientes aleatórios que usam conhecimento da verdadeira Σ.
- **Condicionamento:** o encolhimento melhora o condicionamento da matriz esti-

mada, inclusive quando $p > n$.

- **Custo computacional:** dispensa decomposição espectral e cálculo de determinantes, com custo da mesma ordem que o de S.
- **Livre de distribuição:** exige apenas momentos finitos de ordem oito, sem hipótese de normalidade.

3 Modelos de Aprendizado de Máquina

Os modelos estimam, para cada ativo, a média dos retornos diários dos 21 pregões seguintes, usando atributos disponíveis no instante da previsão. São utilizados retornos defasados de 1, 2, 3 e 5 dias, além da média móvel e da volatilidade de 20 dias. O vetor de previsões $\hat{\boldsymbol{\mu}}$ é fornecido ao otimizador de Markowitz. A Tabela 1 resume as abordagens avaliadas.

Modelo	Síntese
Média histórica	Média dos retornos na janela de treino, sem atributos.
Lasso	Regressão com penalização ℓ_1, que pode zerar coeficientes [4].
Ridge	Regressão com penalização ℓ_2, que reduz os coeficientes [5].
Elastic Net	Combina ℓ_1 e ℓ_2 [6]; neste experimento, $\alpha = 0{,}001$ e $\rho = 0{,}5$.
Random Forest	Agrega árvores em paralelo para capturar não linearidades [7].
Gradient Boosting	Adiciona árvores sequencialmente para corrigir erros [8].
XGBoost	Gradient boosting com regularização e controle de complexidade [9].

Tabela 1: Resumo dos modelos de previsão de retornos

Os modelos são comparados fora da amostra sob o mesmo procedimento temporal, sem informações futuras no treinamento.

4 Metodologia

4.1 Universo de Ativos

O universo configurado contém vinte empresas brasileiras grandes, consolidadas e líquidas. Na execução analisada, dezenove ativos integram a base efetiva: WEGE3.SA não está presente no cache utilizado e não participa das carteiras nem das métricas. A escolha busca representar diferentes setores da economia brasileira, evitando que os resultados sejam dominados por poucas empresas ou por um único setor.

Tabela 2: Universo configurado de empresas

Ticker	Empresa	Ticker	Empresa	Ticker	Empresa
PETR4.SA	Petrobras	VALE3.SA	Vale	ITUB4.SA	Itaú Unibanco
CMIG4.SA	Cemig	ABEV3.SA	Ambev	BBAS3.SA	Banco do Brasil
BBDC4.SA	Bradesco	SANB11.SA	Santander Brasil	B3SA3.SA	B3
SUZB3.SA	Suzano	VIVT3.SA	Telefônica Brasil	EQTL3.SA	Equatorial Energia
RENT3.SA	Localiza	RADL3.SA	Raia Drogasil	TOTS3.SA	Totvs
GGBR4.SA	Gerdau	EGIE3.SA	Engie Brasil	LREN3.SA	Lojas Renner
CSNA3.SA	CSN				

A inclusão dessas empresas é motivada por três critérios: relevância econômica, liquidez e disponibilidade de dados. O carregador remove colunas inteiramente vazias, preenche lacunas remanescentes com o último preço disponível e elimina linhas ainda incompletas. A tabela lista os vinte tickers configurados, assinalando aquele ausente da base efetiva.

4.2 Período Amostral

A consulta foi configurada de 31 de janeiro de 2010 a 31 de janeiro de 2026, sendo a data final exclusiva. O cache efetivo contém preços de 1 de fevereiro de 2010 a 30 de janeiro de 2026, com 3.976 linhas de preços e 3.975 de retornos. Esse intervalo abrange diferentes regimes de mercado, incluindo a crise da Covid-19, permitindo avaliar as estratégias em condições variadas.

A avaliação fora da amostra começa após a janela inicial de treino de 252 pregões e utiliza 177 janelas completas de 21 pregões. As observações restantes ao final não formam uma nova janela de teste no laço implementado.

4.3 Configuração Experimental

Os principais parâmetros do experimento são:

Parâmetro	Valor
Número de ativos	19 efetivos (20 configurados)
Janela de treino	252 pregões
Janela de teste	21 pregões
Rebalanceamento	Aproximadamente mensal
Venda a descoberto	Não permitida
Peso máximo por ativo	15%
γ	5
Custo de transação	0,1% por unidade de turnover
Covariância	Ledoit-Wolf

Tabela 3: Configuração principal do experimento

4.4 Justificativa dos Hiperparâmetros

O parâmetro $\gamma = 5$ representa uma aversão a risco intermediária [10, 11]. Valores muito baixos tenderiam a priorizar excessivamente as previsões de retorno, que são ruidosas em finanças. Valores muito altos poderiam produzir carteiras excessivamente conservadoras. Portanto, $\gamma = 5$ é escolhido como valor central para o experimento principal.

O limite máximo de 15% por ativo é adotado porque o universo contém 19 ações. Sem esse limite, a otimização poderia concentrar capital em poucos ativos, especialmente quando as previsões de retorno fossem muito otimistas para uma empresa específica. Com 19 ativos, um limite de 15% ainda permite convicção em determinados nomes, mas impede concentração extrema.

4.5 Algoritmo do Backtest

O processo de backtest segue uma estrutura de janela móvel. Em cada etapa:

1. seleciona-se uma janela de treino com 252 pregões;
2. constroem-se as variáveis explicativas;
3. treina-se o modelo preditivo;
4. prevê-se o vetor de retornos esperados $\hat{\boldsymbol{\mu}}$;
5. estima-se a matriz de covariância $\hat{\Sigma}$ com Ledoit-Wolf;
6. resolvem-se os pesos pela otimização média-variância com covariância regularizada;
7. aplica-se a carteira nos 21 pregões seguintes;

8. registra-se o retorno composto da carteira;

9. desloca-se a janela para o próximo período.

O retorno da carteira no período de teste é:

$$R_{p,t} = \prod_{\tau \in \mathcal{T}_t} \left(1 + \mathbf{r}_\tau^T \mathbf{w}_t\right) - 1, \tag{10}$$

Nessa equação, $R_{p,t}$ representa o retorno composto da carteira no período de teste associado à etapa t do backtest. O conjunto $\mathcal{T}_t$ contém os dias pertencentes à janela de teste dessa etapa. Como neste trabalho a janela de teste possui 21 pregões, $\mathcal{T}_t$ contém aproximadamente os 21 dias nos quais a carteira é mantida antes do próximo rebalanceamento.

O vetor $\mathbf{r}_\tau$ contém os retornos dos N ativos no dia τ:

$$\mathbf{r}_\tau = \begin{bmatrix} r_{1,\tau} & r_{2,\tau} & \cdots & r_{N,\tau} \end{bmatrix}^T, \tag{11}$$

em que $r_{i,\tau}$ é o retorno do ativo i no dia τ. Já $\mathbf{w}_t$ é o vetor de pesos escolhido pelo otimizador no início da janela de teste:

$$\mathbf{w}_t = \begin{bmatrix} w_{1,t} & w_{2,t} & \cdots & w_{N,t} \end{bmatrix}^T. \tag{12}$$

O termo $\mathbf{r}_\tau^T \mathbf{w}_t$ é o retorno diário da carteira no dia τ. Como $\mathbf{r}_\tau^T$ é um vetor linha e $\mathbf{w}_t$ é um vetor coluna, o produto é uma soma ponderada dos retornos dos ativos:

$$\mathbf{r}_\tau^T \mathbf{w}_t = r_{1,\tau} w_{1,t} + r_{2,\tau} w_{2,t} + \cdots + r_{N,\tau} w_{N,t}. \tag{13}$$

Assim, se a carteira aloca 10% em um ativo, o retorno desse ativo contribui para o retorno diário da carteira na proporção de seu peso, isto é, multiplicado por 0,10. O termo $1 + \mathbf{r}_\tau^T \mathbf{w}_t$ representa o fator de crescimento diário. O produtório acumula esses fatores ao longo da janela de teste, incorporando a composição dos retornos. Para uma janela com dias $\tau_1, \tau_2, \ldots, \tau_{21}$:

$$R_{p,t} = \left(1 + \mathbf{r}_{\tau_1}^T \mathbf{w}_t\right)\left(1 + \mathbf{r}_{\tau_2}^T \mathbf{w}_t\right) \cdots \left(1 + \mathbf{r}_{\tau_{21}}^T \mathbf{w}_t\right) - 1. \tag{14}$$

Na implementação, os mesmos pesos são aplicados aos retornos diários em toda a janela, sem simular sua deriva com a valorização dos ativos. Essa hipótese corresponde à manutenção de pesos constantes dentro da janela. Os custos, porém, incidem somente

sobre mudanças entre os vetores de pesos de janelas consecutivas; negociações intrajanela não são contabilizadas. Equal Weight também utiliza pesos diários constantes, sem desconto explícito de custos. Essas simplificações limitam a interpretação operacional da comparação.

Em cada rebalanceamento após o inicial, aplica-se custo de transação proporcional ao turnover:

$$TO_t = \sum_{i=1}^{N} |w_{i,t} - w_{i,t-1}|, \tag{15}$$

O turnover TO_t mede quanto a carteira mudou entre dois rebalanceamentos consecutivos. O termo $w_{i,t}$ é o peso do ativo i na carteira nova, calculada no instante t, enquanto $w_{i,t-1}$ é o peso do mesmo ativo na carteira anterior. A diferença $w_{i,t} - w_{i,t-1}$ indica a variação de alocação naquele ativo. Como compras e vendas geram custo independentemente do sinal da variação, utiliza-se o valor absoluto:

$$|w_{i,t} - w_{i,t-1}|. \tag{16}$$

Abrindo a soma para N ativos:

$$TO_t = |w_{1,t} - w_{1,t-1}| + |w_{2,t} - w_{2,t-1}| + \cdots + |w_{N,t} - w_{N,t-1}|. \tag{17}$$

Portanto, quanto maior o turnover, maior foi a alteração da carteira e maior tende a ser o custo de transação. Uma estratégia que troca muitos pesos a cada rebalanceamento pode apresentar bom retorno bruto, mas perder parte relevante desse ganho quando os custos são considerados.

$$R_{p,t}^{net} = R_{p,t} - c \cdot TO_t, \tag{18}$$

Nessa equação, $R_{p,t}^{net}$ é o retorno líquido da carteira na janela de teste, após o desconto dos custos de transação. O termo $R_{p,t}$ representa o retorno bruto, e $c = 0{,}001$ corresponde a um custo de 0,1% por unidade de turnover. No backtest, esse custo é descontado do retorno composto da janela a partir do segundo rebalanceamento.

Por exemplo, se $TO_t = 0{,}50$, isso significa que a carteira alterou 50% de sua alocação total em relação ao rebalanceamento anterior. Com $c = 0{,}001$, o custo descontado do retorno da janela é:

$$c \cdot TO_t = 0{,}001 \times 0{,}50 = 0{,}0005, \tag{19}$$

ou seja, 0,05% de retorno. Dessa forma, o backtest avalia não apenas a capacidade da estratégia de gerar retorno, mas também sua robustez a uma aproximação dos custos operacionais.

4.6 Benchmarks

São utilizados dois benchmarks:

- **Equal Weight**: carteira igualmente ponderada entre os 19 ativos;
- **Ibovespa**: principal índice do mercado acionário brasileiro.

Para garantir comparabilidade, os retornos dos benchmarks são agregados nas mesmas janelas de teste de 21 pregões usadas pelas estratégias otimizadas.

5 Métricas de Avaliação

A Tabela 4 resume a avaliação financeira e preditiva. Adota-se $K = 252/21 = 12$ períodos anuais e taxa livre de risco por período $R_{f,K} = (1 + R_f)^{1/K} - 1$. Nas previsões, y_j e $\hat{y}_j$ representam os retornos observado e previsto.

Tabela 4: Resumo das métricas de avaliação

Métrica	Definição	Interpretação
Retorno acumulado	$\prod_{t=1}^{T}(1 + R_{p,t}) - 1$	Ganho total; maior é melhor.
Sharpe anualizado	$\sqrt{K}(\bar{R}_p - R_{f,K})/\sigma_p$	Retorno por risco; maior é melhor.
Máximo drawdown	Maior queda percentual do patrimônio desde um pico.	Quanto menos negativo, melhor.
Turnover médio	Média de $\sum_i \lvert w_{i,t} - w_{i,t-1}\rvert$.	Negociação e base dos custos.
Pesos e concentração	Pesos médios e frequência no limite de alocação.	Distribuição do capital.
MSE	$n^{-1}\sum_j (y_j - \hat{y}_j)^2$	Erro quadrático; menor é melhor.
MAE	$n^{-1}\sum_j \lvert y_j - \hat{y}_j\rvert$	Erro absoluto; menor é melhor.
Acurácia direcional	Fração de sinais previstos corretamente.	Maior é melhor.

A precisão preditiva não garante melhor resultado financeiro. As métricas são analisadas em conjunto, considerando os custos proporcionais ao turnover e o rebalanceamento mensal.

6 Resultados

6.1 Tabela de Desempenho

A Tabela 5 apresenta os resultados do procedimento final, aplicado a 19 ativos no período de 2010 a 2026. Os valores permitem comparar as estratégias em duas dimensões: desempenho financeiro, medido pelo Sharpe, pelo retorno acumulado e pelo drawdown; e desempenho preditivo, medido por MSE, MAE e acurácia direcional.

Estratégia	Sharpe	Retorno acum.	Drawdown	MSE	MAE	Direção
Ridge + Markowitz	0,717	9,388	-0,333	0,000059	0,005587	0,487
XGBoost + Markowitz	0,712	7,604	-0,311	0,000031	0,004065	0,503
Equal Weight	0,699	8,029	-0,326	–	–	–
Elastic Net + Markowitz	0,677	7,216	-0,293	0,000044	0,004381	0,508
Lasso + Markowitz	0,660	6,856	-0,329	0,000041	0,004113	0,507
Média histórica + Markowitz	0,654	5,346	-0,271	0,000025	0,003642	0,512
Random Forest + Markowitz	0,617	5,802	-0,337	0,000033	0,004106	0,497
Gradient Boosting + Markowitz	0,610	5,508	-0,339	0,000033	0,004123	0,506
Ibovespa	0,305	1,504	-0,433	–	–	–

Tabela 5: Resumo do desempenho das estratégias

As colunas MSE, MAE e Direção são métricas preditivas e, portanto, só são calculadas para estratégias que produzem previsões explícitas de retorno esperado. Por esse motivo, a carteira igualmente ponderada e o Ibovespa aparecem com "–" nessas colunas. A carteira Equal Weight é um benchmark de alocação fixa, sem modelo de previsão, enquanto o Ibovespa é um índice de mercado usado como referência externa. Assim, ambos possuem métricas financeiras, como Sharpe, retorno acumulado e drawdown, mas não possuem erro de previsão ou acurácia direcional.

Na tabela, o retorno acumulado é expresso em escala decimal e representa o ganho total do backtest, não o patrimônio final. Assim, 9,388 equivale a um ganho de 938,8% e a um patrimônio final de aproximadamente 10,388 vezes o capital inicial. Na Figura 1, esse mesmo retorno é apresentado em porcentagem.

No universo e no período analisados, todas as estratégias com as 19 ações superam o Ibovespa nas métricas financeiras apresentadas. O índice registra Sharpe de 0,305, retorno acumulado de 1,504 e drawdown máximo de -0,433. As carteiras do experimento apresentam Sharpe entre 0,610 e 0,717 e retornos acumulados entre 5,346 e 9,388. Essa

diferença descreve o desempenho observado neste recorte, mas não demonstra, por si só, que as estratégias superariam o mercado em outros universos ou períodos.

Entre as estratégias testadas, Ridge + Markowitz apresenta o maior Sharpe (0,717) e o maior retorno acumulado (9,388). XGBoost e a carteira igualmente ponderada também apresentam resultados competitivos, com Sharpes de 0,712 e 0,699 e retornos acumulados de 7,604 e 8,029, respectivamente. Ainda assim, essas métricas isoladas não bastam para concluir que um modelo seja superior: é necessário considerar também o drawdown, os custos e a estabilidade dos resultados.

As métricas preditivas também indicam que a qualidade da previsão não se traduz diretamente em desempenho da carteira. A média histórica apresenta os menores MSE e MAE e a maior acurácia direcional (0,512), mas não lidera em retorno ou Sharpe. Ridge + Markowitz obtém os maiores valores nessas duas métricas financeiras, embora tenha uma acurácia direcional inferior a 0,5. Assim, um menor erro preditivo não implica necessariamente uma carteira com melhor desempenho.

6.2 Retorno Acumulado

A Figura 1 apresenta o retorno acumulado das estratégias ao longo do backtest. O gráfico mostra que as estratégias baseadas no universo de 19 ações seguem trajetórias relativamente próximas, principalmente até meados de 2016. A partir desse período, as curvas passam a se separar com mais intensidade, refletindo diferenças nas previsões, nos pesos otimizados e na exposição aos ativos que mais se valorizaram.

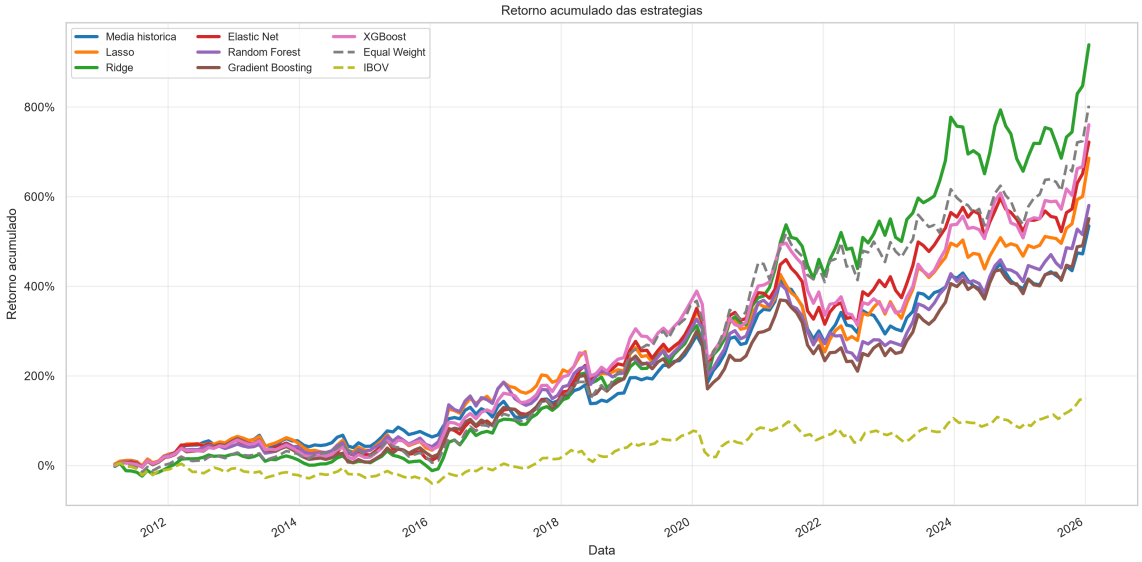


Figura 1: Retorno acumulado das estratégias

Ridge + Markowitz apresenta o maior retorno acumulado ao final da amostra.

A carteira igualmente ponderada também tem desempenho competitivo, apesar de não utilizar previsões nem otimização. A proximidade entre algumas estratégias mostra que a complexidade adicional dos modelos não garante, por si só, uma vantagem consistente.

O Ibovespa, representado pela linha tracejada, fica consistentemente abaixo das demais estratégias durante grande parte do período. Mesmo quando acompanha alguns movimentos de recuperação, sua trajetória acumulada termina muito inferior à das carteiras construídas com o universo selecionado. Essa diferença sugere que a escolha do universo de ativos teve papel relevante no desempenho final.

O gráfico também evidencia quedas importantes em momentos de crise, especialmente em 2020. Ainda assim, as estratégias recuperam rapidamente parte das perdas e voltam a crescer nos anos seguintes. Esse comportamento indica que o desempenho acumulado foi marcado por ciclos de queda e recuperação, e não por uma trajetória linear.

6.3 Drawdown

A Figura 2 apresenta o drawdown das estratégias. Essa análise é relevante porque duas estratégias podem ter retornos acumulados semelhantes, mas riscos de queda bastante diferentes. O drawdown mostra a perda em relação ao pico anterior da própria estratégia, permitindo observar a profundidade e a frequência das quedas.

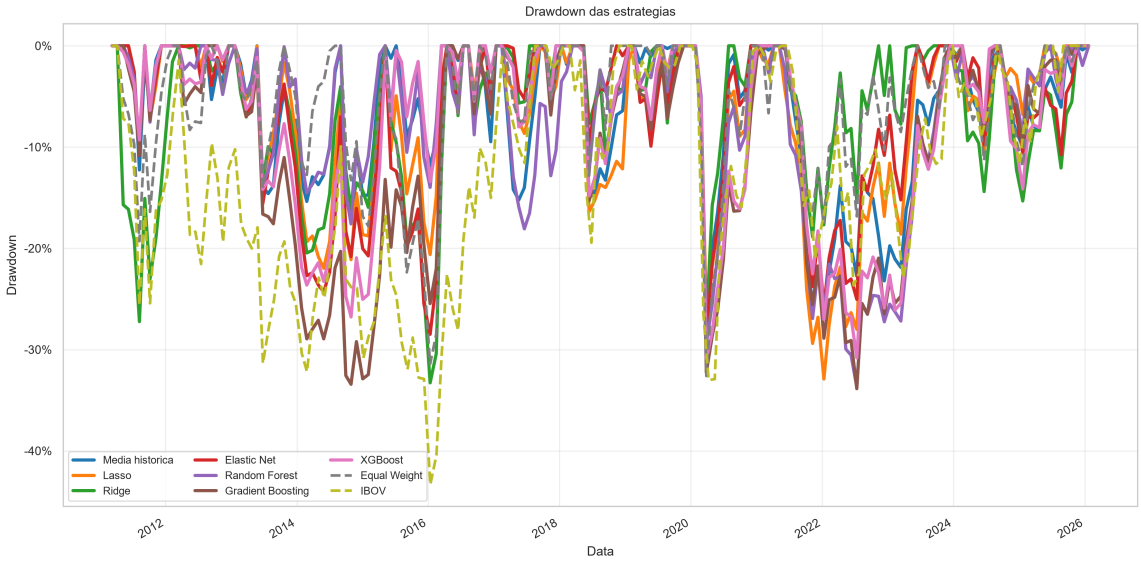


Figura 2: Drawdown das estratégias

O principal destaque é o drawdown mais profundo do Ibovespa, que chega a aproximadamente -43%, conforme também aparece na Tabela 5. As estratégias do experimento apresentam drawdowns máximos menores, entre aproximadamente -27% e -34%. Essa diferença ajuda a explicar por que o Sharpe do Ibovespa é tão inferior: além de menor

retorno acumulado, o índice também sofreu quedas mais severas.

Entre as estratégias baseadas em Markowitz e a carteira igualmente ponderada, os drawdowns são relativamente próximos. A média histórica apresenta o menor drawdown máximo (-0,271), enquanto Random Forest e Gradient Boosting registram as quedas mais profundas entre as estratégias do universo selecionado (-0,337 e -0,339, respectivamente). Ainda assim, os drawdowns de todas essas estratégias são menos severos que o do Ibovespa.

O gráfico mostra episódios de queda relevantes em 2011, 2015–2016, 2020 e 2022. Em 2020, praticamente todas as estratégias apresentam queda acentuada, o que é coerente com o choque da crise da Covid-19. O fato de as curvas caírem de forma parecida nesses momentos sugere que, em crises sistêmicas, a diversificação dentro do universo de ações brasileiras não elimina completamente o risco de mercado.

6.4 Risco versus Retorno

A Figura 3 apresenta a relação entre retorno médio e volatilidade por período. Estratégias localizadas mais acima e à esquerda tendem a ser preferíveis, pois combinam maior retorno médio com menor volatilidade. Essa visualização ajuda a entender por que estratégias com retornos acumulados próximos podem ter índices de Sharpe diferentes.

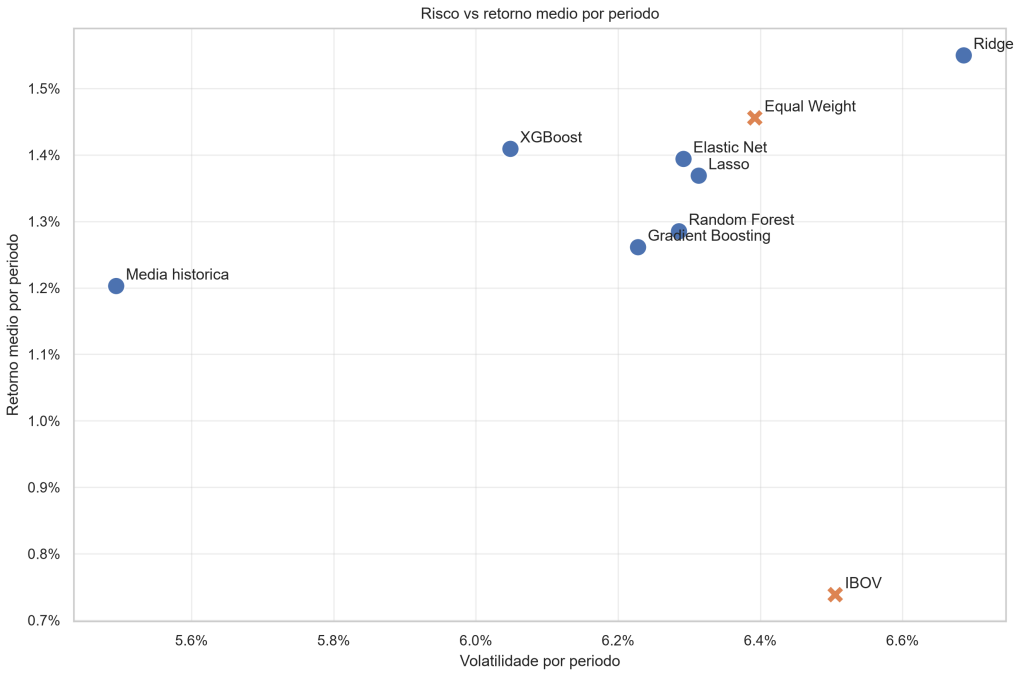


Figura 3: Risco versus retorno médio por período

O gráfico mostra que a maior parte das estratégias se concentra em uma faixa relativamente estreita de volatilidade por período. Isso indica que as diferenças de risco

entre os modelos não são muito grandes. A principal separação visual ocorre no eixo de retorno médio e na posição isolada do Ibovespa.

Ridge aparece em posição favorável, com retorno médio elevado e volatilidade compatível com o maior Sharpe da tabela. A carteira igualmente ponderada também apresenta retorno médio competitivo, enquanto a média histórica se destaca pelo menor MSE e MAE, mas não pelo maior retorno financeiro.

Embora Ridge lidere em retorno acumulado e Sharpe, seu drawdown máximo (-0,333) é mais profundo que o do Elastic Net e o da média histórica. Gradient Boosting registra o menor Sharpe entre as carteiras do universo selecionado. O Ibovespa apresenta o menor Sharpe e o maior drawdown, indicando a relação risco-retorno menos favorável neste período.

6.5 Resumo das Métricas

A Figura 4 apresenta uma comparação direta entre Sharpe, retorno acumulado e máximo drawdown. Essa figura resume visualmente os resultados da Tabela 5.

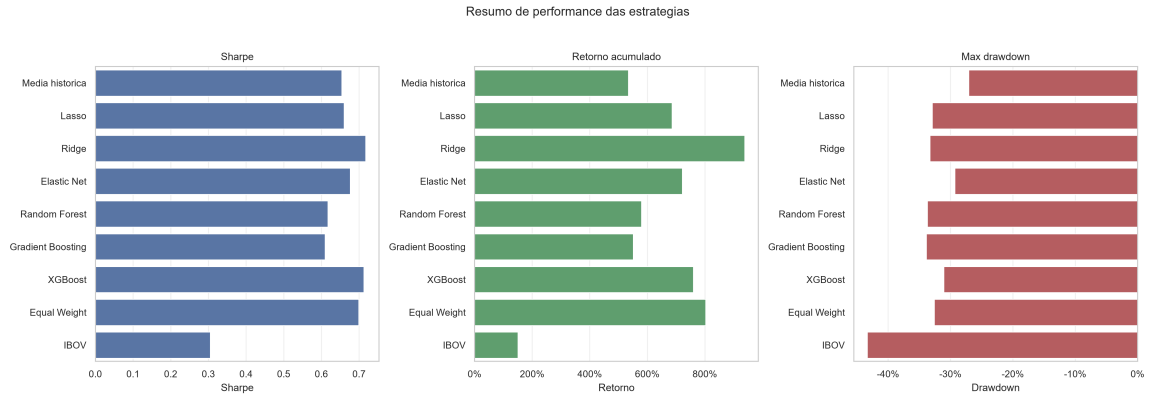


Figura 4: Resumo das métricas de desempenho

No painel de Sharpe, Ridge, XGBoost e Equal Weight formam o grupo de melhor desempenho, embora as demais estratégias também superem o Ibovespa. As diferenças entre modelos não indicam uma vantagem uniforme dos métodos mais sofisticados em relação às alternativas simples.

No painel de retorno acumulado, Ridge lidera, seguido pela carteira igualmente ponderada e pelo XGBoost. A média histórica apresenta o menor retorno acumulado entre as estratégias do universo de 19 ativos, embora ainda supere o Ibovespa. No painel de drawdown, o Ibovespa apresenta a barra mais negativa, enquanto as demais estratégias permanecem em uma faixa menos severa.

Em conjunto, esses resultados sugerem que o ganho principal não vem apenas da es-

colha de um modelo de aprendizado de máquina específico. A combinação entre universo de ativos, restrições de alocação, diversificação, estimação de covariância e rebalanceamento mensal parece ter sido tão importante quanto a capacidade preditiva individual dos modelos.

6.6 Pesos Médios

A Figura 5 mostra os pesos médios atribuídos a cada ativo por cada estratégia baseada em Markowitz. Esse gráfico é útil para verificar se os modelos concentram capital em poucos ativos ou se mantêm diversificação razoável ao longo do backtest.

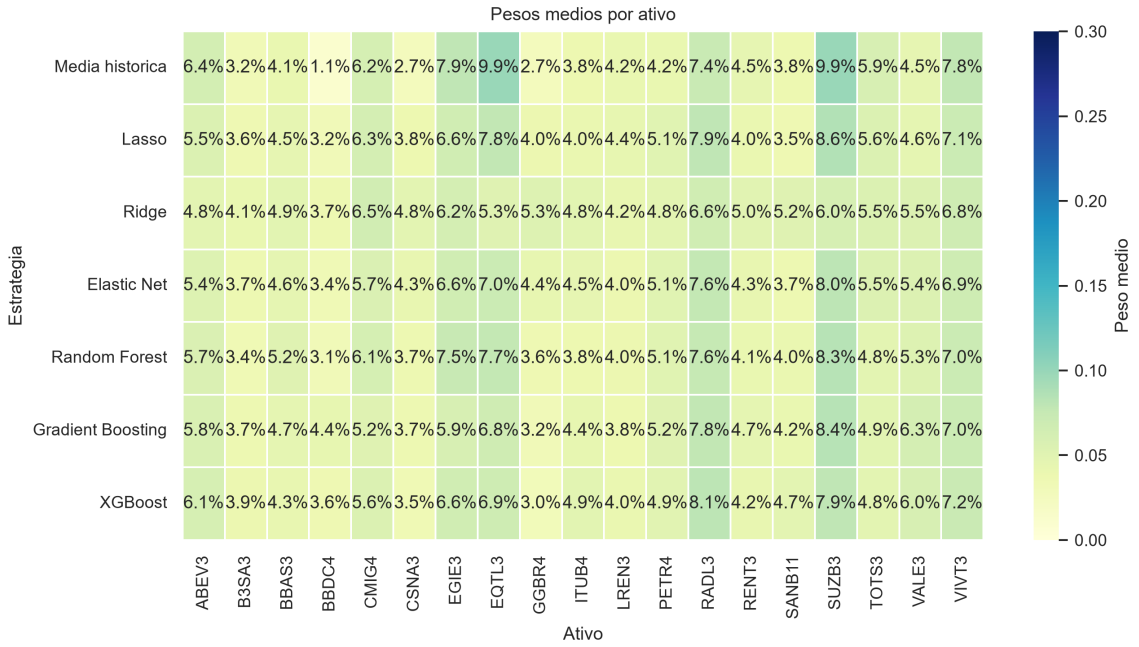


Figura 5: Pesos médios por ativo

Os pesos médios variam aproximadamente de 1,1% a 9,9% no conjunto de estratégias. Como a base efetiva contém 19 ativos, uma carteira igualmente ponderada atribui aproximadamente 5,26% a cada ação. Na média histórica, BBDC4 recebe cerca de 1,1%, enquanto EQTL3 e SUZB3 recebem cerca de 9,9%. Portanto, o mapa de calor revela diferenças persistentes de alocação.

Pesos médios não permitem concluir que as carteiras sejam pouco concentradas em cada rebalanceamento. Para $\gamma = 5$, os diagnósticos da média histórica e do Ridge mostram que o maior peso por janela fica, em média, próximo do limite de 15%. O índice de concentração $HHI_t = \sum_i w_{i,t}^2$ médio é aproximadamente 0,135 e 0,143, respectivamente, acima de $1/19 \approx 0,053$ para Equal Weight.

Ridge apresenta pesos médios mais uniformes, aproximadamente entre 3,7% e 6,8%,

enquanto Elastic Net apresenta valores entre 3,4% e 8,0%. A relativa uniformidade das médias do Ridge convive com concentração por janela e mudanças frequentes de alocação. A regularização aplicada no código é a da matriz de covariância; não há penalização adicional que force os pesos a permanecer próximos de Equal Weight.

6.7 Diagnósticos do Backtest

O Sharpe apresentado usa taxa livre de risco anual fixa de 2%, convertida para a frequência das janelas, e desvio padrão populacional dos retornos, conforme a implementação. Os drawdowns são calculados sobre retornos compostos por janela de 21 pregões; portanto, não representam necessariamente as maiores perdas dentro de cada janela. MSE, MAE e acurácia direcional comparam as previsões à média diária realizada de cada ativo nos 21 pregões seguintes, agregando ativos e janelas; não avaliam diretamente o retorno composto da carteira.

Além das métricas principais, foram realizados diagnósticos para verificar a consistência do experimento. O primeiro diagnóstico avaliou a anualização do Sharpe. Como os retornos do backtest são por janelas de aproximadamente 21 pregões, a anualização correta utiliza aproximadamente 12 períodos por ano, e não 252.

Nos diagnósticos da média histórica e do Ridge, para $\gamma \in \{1, 5, 10\}$, foram observadas 177 janelas de teste, todas com 21 pregões, precedidas por janelas de treino de 252 pregões. A contagem observada de sobreposição entre treino e teste de uma mesma etapa foi:

$$overlap_count = 0. \tag{20}$$

Isso confirma a separação cronológica entre treino e teste nas etapas verificadas. Isoladamente, essa contagem não constitui uma auditoria de todas as fontes possíveis de vazamento. Também foram analisados turnover, custos de transação e concentração dos pesos.

Com $\gamma = 5$, o turnover médio entre janelas é 1,207 para Ridge e 0,324 para a média histórica, segundo a definição $\sum_i |w_{i,t} - w_{i,t-1}|$. Sem custos, Ridge apresenta Sharpe de 0,779 e retorno acumulado de 11,814; com custo de 0,1%, esses valores caem para 0,717 e 9,388. Com custo de 0,5%, seu Sharpe cai para 0,469 e seu retorno para 3,475, abaixo dos 0,572 e 4,059 da média histórica. Portanto, a liderança do Ridge não se mantém em todos os cenários de custo.

A sensibilidade a γ também altera a comparação. Com custo de 0,1% e $\gamma = 10$, a média histórica apresenta Sharpe de 0,744 e retorno de 6,211, enquanto Ridge apresenta

Sharpe de 0,703 e retorno de 7,860. Assim, o maior retorno acumulado não implica o maior Sharpe. Esses testes abrangem apenas média histórica e Ridge e não estabelecem robustez dos demais modelos.

Portanto, os resultados devem ser lidos em conjunto: retorno acumulado, Sharpe, drawdown, turnover e concentração contam partes diferentes da mesma história. A melhor estratégia não é necessariamente aquela com maior retorno bruto, mas aquela que combina desempenho, estabilidade e robustez operacional.

7 Discussão dos Resultados

7.1 Desempenho Financeiro e Qualidade Preditiva

Os resultados evidenciam o papel da construção de carteiras na transformação de previsões em desempenho financeiro. Na configuração principal, com $\gamma = 5$ e custo de transação de 0,1%, Ridge + Markowitz apresentou o maior Sharpe (0,717) e o maior retorno acumulado (9,388). XGBoost e Equal Weight também tiveram desempenho competitivo, enquanto a média histórica se destacou pelos menores erros de previsão e pelo drawdown menos severo.

A diferença entre esses resultados ajuda a responder à pergunta central do trabalho. A média histórica obteve os menores MSE e MAE e a maior acurácia direcional, mas Ridge gerou a carteira de maior retorno e Sharpe. Assim, a qualidade preditiva deve ser avaliada em conjunto com a matriz de covariância, as restrições de alocação e os custos. Um modelo com menor erro médio não produz necessariamente a melhor combinação de ativos.

O desempenho do Ridge mostra que um modelo linear regularizado pode ser uma alternativa competitiva nesse processo. Os modelos mais flexíveis não apresentaram vantagem uniforme sobre as alternativas simples, o que sugere que a complexidade do preditor, por si só, não determina o resultado da carteira. A combinação entre previsão, estimação de risco e otimização é o elemento central da abordagem avaliada.

7.2 Benchmarks e Composição das Carteiras

A carteira igualmente ponderada constitui uma referência relevante: seu Sharpe de 0,699 e seu retorno acumulado de 8,029 a colocam próxima das estratégias de melhor desempenho. Esse resultado destaca a contribuição da diversificação no universo selecionado e oferece um critério prático para avaliar o ganho adicional dos modelos e da otimização.

Todas as estratégias do experimento superaram o Ibovespa nas métricas financeiras apresentadas. Essa comparação descreve o desempenho dos dezenove ativos efetivamente

carregados em relação ao índice, que possui composição e ponderação próprias. A escolha do universo também participa dessa diferença, de modo que o resultado não deve ser atribuído exclusivamente ao método preditivo.

Os pesos médios mostram perfis distintos de alocação. Ridge apresenta médias mais uniformes entre os ativos, enquanto a média histórica mantém diferenças mais acentuadas. Os diagnósticos complementam essa leitura ao mostrar concentração por janela e maior turnover do Ridge. Portanto, as médias no tempo e as mudanças entre rebalanceamentos descrevem aspectos diferentes da gestão da carteira.

As quedas observadas em períodos de crise, especialmente em 2020, mostram ainda que as estratégias permanecem expostas aos movimentos gerais do mercado. A estimação regularizada da covariância e as restrições de peso organizam essa exposição, sem eliminar o risco sistêmico.

7.3 Sensibilidade e Implicações Práticas

Os testes com média histórica e Ridge mostram como custos e aversão a risco influenciam a escolha da estratégia. Com $\gamma = 5$, Ridge apresenta turnover médio de 1,207, contra 0,324 da média histórica. Na taxa principal de 0,1%, Ridge lidera em retorno e Sharpe; com custo de 0,5%, a média histórica passa a apresentar valores maiores nas duas métricas. A estabilidade das alocações, portanto, tem efeito direto sobre o resultado líquido.

A variação de γ também permite distinguir objetivos de investimento. Com $\gamma = 10$ e custo de 0,1%, a média histórica apresenta Sharpe de 0,744, superior ao 0,703 do Ridge, enquanto Ridge mantém o maior retorno acumulado, de 7,860 contra 6,211. A escolha entre essas carteiras depende, assim, da importância atribuída ao retorno total, ao risco e ao custo de implementação.

Em conjunto, as evidências favorecem a avaliação integrada de métricas preditivas e financeiras. Ridge se destaca na configuração principal, Equal Weight oferece uma referência competitiva de simplicidade e a média histórica combina boa qualidade preditiva com menor turnover. Esses resultados descrevem a amostra e os parâmetros avaliados; as diferenças observadas não estabelecem, isoladamente, significância estatística.

7.4 Alcance da Análise e Extensões

O período de 2010 a 2026 permite observar diferentes condições de mercado, mas as conclusões permanecem associadas ao universo selecionado. A seleção de empresas com histórico disponível pode introduzir viés de sobrevivência. Ampliar a amostra e reconstruir

os ativos elegíveis em cada data são extensões que permitiriam avaliar a generalização dos resultados.

A implementação utiliza pesos diários constantes dentro de cada janela e custos proporcionais às mudanças dos pesos entre janelas, sem contabilizar negociações intrajanela; Equal Weight não recebe desconto explícito de custos. Os drawdowns são medidos na frequência das janelas de 21 pregões. Essas escolhas definem a aproximação operacional adotada e devem ser consideradas ao transportar os resultados para uma aplicação prática.

Como continuidade, podem ser explorados atributos macroeconômicos e fatores de mercado, ajustes temporais de hiperparâmetros e testes em outros períodos. Essas extensões permitiriam investigar a estabilidade dos padrões preditivos diante de mudanças de regime e aprofundar a análise de custos e execução, mantendo os benchmarks simples como referência.

8 Conclusão

Este trabalho avaliou a combinação de previsões de aprendizado de máquina com a otimização de Markowitz e a estimação de covariância por Ledoit-Wolf no mercado acionário brasileiro. Na amostra de dezenove ativos, Ridge apresentou os maiores Sharpe e retorno acumulado na configuração principal, enquanto a média histórica obteve as melhores métricas preditivas e Equal Weight permaneceu competitivo.

A resposta à pergunta central é que o aprendizado de máquina pode contribuir para a alocação, mas o experimento não demonstrou vantagem uniforme sobre alternativas simples. O menor erro de previsão não se traduziu necessariamente em melhor carteira, e a comparação entre estratégias variou com os custos e a aversão a risco.

A principal contribuição do estudo é mostrar a importância de avaliar previsão e construção de carteira em conjunto. Para a aplicação prática, a escolha do modelo deve considerar o ganho financeiro adicional, a estabilidade das alocações e os custos de implementação, além da precisão preditiva.

Referências

[1] MARKOWITZ, H. Portfolio Selection. *The Journal of Finance*, v. 7, n. 1, p. 77–91, 1952.

[2] LEDOIT, O.; WOLF, M. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, v. 88, n. 2, p. 365–411, 2004.

[3] SHARPE, W. F. Mutual Fund Performance. *The Journal of Business*, v. 39, n. 1, p. 119–138, 1966.

[4] TIBSHIRANI, R. Regression Shrinkage and Selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, v. 58, n. 1, p. 267–288, 1996.

[5] HOERL, A. E.; KENNARD, R. W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, v. 12, n. 1, p. 55–67, 1970.

[6] ZOU, H.; HASTIE, T. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, v. 67, n. 2, p. 301–320, 2005.

[7] BREIMAN, L. Random Forests. *Machine Learning*, v. 45, p. 5–32, 2001.

[8] FRIEDMAN, J. H. Greedy Function Approximation: A Gradient Boosting Machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001.

[9] CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.

[10] LIU, S.; XU, R. *The Effects of Risk Aversion on Optimization*. MSCI Barra Research Paper No. 2010-06, 2010.

[11] BODNAR, T.; PAROLO, S.; SCHMID, W. Determination and Estimation of Risk Aversion Coefficients. Working Paper, Stockholm University, 2015.